

CASO - PREDICTING CUSTOMER CHURN AT QWE INC.



PRESENTADO POR:

**DAVID SANTIAGO AGUIRRE POLANCO
ANDRÉS FELIPE ROMERO RODRÍGUEZ
MARÍA JUANITA ROJAS CHACÓN**

PRESENTADO A:

PROFESOR JUAN NICOLÁS VELÁSQUEZ REY

**ANALÍTICA DE LOS NEGOCIOS
CASO 4**

**PONTIFICIA UNIVERSIDAD JAVERIANA
BOGOTÁ, D.C.
ABRIL 29
2026**

Contenido

1. Introducción.....	3
2. Contexto.....	3
3. Base de datos	4
4. Resultados y análisis.....	4
4.1 Tabla descriptiva de los datos	4
4.2 Análisis exploratorio de variables relevantes.....	5
4.3 Especificación del modelo de probabilidad binaria	9
4.4 Estimación del modelo	10
4.5 Selección del modelo final	13
4.6 Interpretación de coeficientes relevantes	14
4.7 Evaluación del desempeño del modelo	16
4.7.1 Análisis de las probabilidades estimadas.....	16
4.7.2 Gráfico de errores	17
4.7.3 Matriz de confusión	19
4.7.4 Métricas de clasificación	19
4.7.5 Curva ROC y capacidad de discriminación del modelo.....	20
4.8 Identificación de clientes con mayor riesgo de churn	21
4.9 Principales drivers del churn	26
5. 4D de las IA	28
5.1 Definir	28
5.2 Diagnosticar	28
5.3 Discernimiento	29
5.4 Diligencia	30
6. Conclusiones y recomendaciones	31

1. Introducción

La deserción de clientes (churn) representa uno de los principales desafíos estratégicos para empresas basadas en modelos de suscripción, como es el caso de QWE Inc., cuya propuesta de valor depende de la retención sostenida de sus usuarios. A medida que la compañía experimentó un crecimiento acelerado, se hizo evidente la necesidad de complementar su enfoque operativo con herramientas analíticas que permitieran comprender mejor el comportamiento de sus clientes y anticipar posibles cancelaciones. En este contexto, la empresa pasó de una estrategia reactiva, basada en responder a solicitudes de cancelación con incentivos, a la búsqueda de un enfoque proactivo orientado a predecir la probabilidad de abandono y actuar oportunamente para mitigarlo.

El presente trabajo se enfoca en la estimación de un modelo de probabilidad para una variable binaria, con el objetivo de identificar los factores que inciden en la deserción y predecir qué clientes tienen mayor riesgo de abandonar el servicio en el corto plazo. Para ello, se estiman modelos de probabilidad como el modelo de probabilidad lineal (MPL), logit y probit, con el fin de determinar cuál presenta un mejor desempeño predictivo. A partir del análisis de variables relevantes como la antigüedad del cliente, el índice de satisfacción (CHI) y los patrones de uso del servicio, se busca no solo construir un modelo estadístico robusto, sino también generar insights accionables para la toma de decisiones. De igual forma, se examinará la precisión del modelo y su capacidad predictiva, buscando garantizar que los resultados sean consistentes y útiles para la toma de decisiones.

2. Contexto

QWE Inc. es una empresa que ofrece servicios por suscripción orientados a ayudar a pequeñas y medianas empresas a gestionar su presencia en línea. Su modelo de negocio se basa en contratos mensuales o de duración fija (6 o 12 meses), lo que facilita que los clientes puedan cancelar el servicio con relativa flexibilidad. Durante sus primeras etapas, la compañía experimentó un crecimiento acelerado, sin embargo, con el paso del tiempo, surgió la necesidad de comprender mejor los factores que afectan la permanencia de los clientes, especialmente ante la creciente preocupación por la deserción. Hasta ese momento, la organización manejaba un enfoque reactivo, en el que solo actuaba cuando el cliente manifestaba su intención de cancelar, generalmente ofreciendo descuentos o beneficios adicionales para intentar retenerlo.

Ante esta situación, la dirección de servicio al cliente planteó la importancia de migrar hacia un enfoque más proactivo, basado en el uso de datos para anticipar el comportamiento de los usuarios. Para ello, se recopiló información detallada de aproximadamente 6.000 clientes, incluyendo variables como la antigüedad, el nivel de satisfacción (CHI), el uso del servicio y las interacciones con soporte técnico. El objetivo central consistía en identificar patrones que permitieran estimar la probabilidad de que un cliente abandonara el servicio en el corto plazo, lo cual permitiría priorizar intervenciones de retención, optimizar recursos y mejorar la experiencia del cliente. De esta manera, la empresa podría reducir la deserción sin depender exclusivamente de incentivos económicos.

3. Base de datos

La base de datos utilizada en este caso corresponde a una muestra de aproximadamente 6.000 clientes de QWE Inc., recopilada a partir del sistema interno de la compañía. Esta información fue estructurada con el propósito de analizar el comportamiento de los usuarios en un momento específico del tiempo y relacionarlo con su decisión de abandonar o permanecer en el servicio. En particular, se construyó una variable binaria que indica si el cliente desertó en un periodo posterior, lo que permite abordar el problema desde un enfoque de modelos de probabilidad. Además, la base incluye múltiples variables explicativas que capturan características relevantes de cada cliente, facilitando un análisis integral de los factores asociados a la deserción.

Entre las variables disponibles se encuentran indicadores como la antigüedad del cliente (Customer Age), el índice de satisfacción (CHI), el número de casos de soporte, la prioridad de dichos casos y diversas métricas de uso del servicio, como inicios de sesión, publicaciones y visualizaciones. Asimismo, la base incorpora tanto valores en un momento determinado como sus variaciones recientes, lo que permite evaluar no solo el estado actual del cliente, sino también su evolución en el tiempo. Esta estructura permite capturar tanto el nivel como la dinámica del comportamiento del cliente, lo cual resulta fundamental para la construcción de modelos predictivos de churn.

4. Resultados y análisis

4.1 Tabla descriptiva de los datos

Como primer paso del análisis, se presenta una caracterización general de las variables utilizadas en el estudio del churn, con el objetivo de identificar patrones iniciales en el comportamiento de los clientes. Esta exploración permite detectar niveles de dispersión, posibles valores atípicos y diferencias en el uso de la plataforma o en la experiencia de soporte, los cuales pueden ser relevantes para explicar la probabilidad de abandono.

Variable	Mínimo	Promedio	Desviación	Máximo
Churn	0.0000	0.0509	0.2198	1.0000
Customer_Age	0.0000	13.8968	11.1601	67.0000
CHI_Score	0.0000	87.3167	66.2828	298.0000
CHI_Change	-125.0000	5.0586	30.8288	208.0000
Support_Cases	0.0000	0.7063	1.7240	32.0000
Support_Cases_Change	-29.0000	-0.0069	1.8709	31.0000
Support_Priority	0.0000	0.8128	1.3205	4.0000
Support_Priority_Change	-4.0000	0.0302	1.4603	4.0000
Logins	-293.0000	15.7279	42.1191	865.0000
Blog_Articles	-75.0000	0.1572	4.6606	217.0000
Views	-28322.0000	96.3105	3152.4117	230414.0000

Days_Since_Last_Login	-648.0000	1.7646	17.9660	61.0000
-----------------------	-----------	--------	---------	---------

Tabla 1. Estadísticas descriptivas de las variables del modelo.

La tabla evidencia que las variables no presentan un comportamiento homogéneo. Por ejemplo, Views registra una desviación estándar de 3152.4117, con valores que van desde -28322 hasta 230414, mientras que Logins presenta una desviación de 42.1191, con un rango entre -293 y 865. Estos resultados muestran una alta variabilidad en la interacción de los clientes con la plataforma, sugiriendo que algunos usuarios incrementan fuertemente su actividad mientras otros la reducen de manera significativa, lo que puede constituir una señal temprana de churn.

En cuanto a las variables de soporte, Support_Cases presenta un promedio relativamente bajo (0.7063), pero con un valor máximo de 32, lo que evidencia la existencia de clientes con una alta demanda de atención. Asimismo, Support_Cases_Change oscila entre -29 y 31, reflejando cambios importantes en el tiempo. Esta heterogeneidad sugiere que la experiencia de soporte no es uniforme entre los clientes, y que incrementos en la necesidad de soporte podrían estar asociados a problemas en el servicio o niveles de insatisfacción.

Por otro lado, las variables relacionadas con el estado del cliente también muestran variabilidad relevante. CHI_Score presenta una desviación estándar de 66.2828 y un máximo de 298, mientras que CHI_Change varía entre -125 y 208, lo que indica cambios significativos en el nivel de engagement del cliente. Es importante resaltar que varias de estas variables corresponden a variaciones entre períodos, lo que explica la presencia de valores negativos; estos deben interpretarse como reducciones en la actividad y no como valores inconsistentes. En este sentido, Days_Since_Last_Login presenta una desviación de 17.9660, con valores entre -648 y 61, lo que permite capturar cambios en la frecuencia de uso, un factor clave en la detección de posibles abandonos.

Finalmente, la variable Churn tiene un promedio de 0.0509, lo que indica que aproximadamente el 5.09% de los clientes abandonaron el servicio. Este resultado evidencia un desbalance en la muestra, con una clara predominancia de clientes activos. Por consiguiente, los patrones observados sugieren que el churn podría estar estrechamente relacionado con la disminución en el uso de la plataforma, cambios en el nivel de engagement y experiencias heterogéneas en el soporte. Estas señales iniciales justifican la posterior estimación de modelos de probabilidad que permitan cuantificar estas relaciones.

4.2 Análisis exploratorio de variables relevantes

Con el fin de profundizar en el comportamiento de los clientes, se realiza un análisis exploratorio mediante gráficos que comparan los grupos con y sin churn. Lo que permite identificar diferencias visibles en variables clave asociadas al uso de la plataforma, el nivel de engagement y la interacción con el servicio, aportando evidencia preliminar sobre los factores que podrían influir en la decisión de abandono.




Ilustración 1. Distribución de clientes según condición de churn.

La distribución evidencia un marcado desbalance en la muestra en el cual se obtuvo 6.024 clientes sin churn frente a 323 con churn, lo que equivale a aproximadamente un 94,91% de permanencia y un 5,09% de abandono. Esto confirma que el churn es un evento poco frecuente, lo cual es relevante para el análisis posterior, ya que implica que los modelos deberán identificar patrones en un grupo minoritario. Desde una perspectiva empresarial, esto refuerza la importancia de detectar tempranamente a estos clientes, dado que, aunque son pocos, representan una pérdida potencial de valor.




Ilustración 2. Boxplot del CHI Score según condición de churn.

Este gráfico compara el CHI Score entre los clientes sin churn y los clientes con churn. Se puede observar que los clientes sin churn tienen valores más altos de CHI Score, mientras que los clientes con churn presentan valores más bajos. En promedio, los clientes sin churn tienen un CHI Score aproximado de 88,61, mientras que los clientes con churn tienen un promedio de 63,27. Los clientes con menor CHI Score tienden a abandonar más. Esta es una diferencia visible entre ambos grupos, ya que el grupo con churn se concentra en niveles más bajos del indicador.

El CHI Score puede interpretarse como una medida de salud, actividad o relación del cliente con la empresa. Si un cliente tiene un CHI Score bajo, puede significar que usa menos el servicio, que está menos comprometido o que su relación con la empresa se ha debilitado. Por eso, este gráfico sugiere que una caída en el CHI Score puede ser una señal temprana de riesgo de churn.




Ilustración 3. Boxplot del número de logins según condición de churn.

El Boxplot del número de logins según condición de churn compara el número de logins entre clientes sin churn y clientes con churn. Se observa que los clientes sin churn tienen más ingresos a la plataforma que los clientes con churn. En promedio, los clientes sin churn registran aproximadamente 16,14 logins, mientras que los clientes con churn registran cerca de 8,06 logins. Teniendo en cuenta que, los logins reflejan el nivel de interacción del cliente con el servicio, un cliente que ingresa con frecuencia probablemente encuentra utilidad en la plataforma y mantiene una relación activa con la empresa. En cambio, cuando los logins disminuyen, puede haber desinterés, menor necesidad del servicio o pérdida de vínculo con la marca. Por eso, una reducción en los logins puede funcionar como alerta de posible abandono.




Ilustración 4. Boxplot de los días desde el último login según condición de churn.

Este gráfico compara los días desde el último ingreso entre clientes sin churn y clientes con churn. En donde se observa que los clientes con churn tienden a tener más días desde su último login. En promedio, los clientes sin churn tienen alrededor de 1,51 días desde el último ingreso, mientras que los clientes con churn tienen aproximadamente 6,49 días. Este patrón es muy importante porque muestra una señal clara de desconexión. Cuando un cliente deja de ingresar o aumenta el tiempo desde su último login, puede estar perdiendo interés en el servicio. Por eso, esta variable ayuda a identificar clientes que se están alejando antes de abandonar definitivamente.




Ilustración 5. Boxplot del número de casos de soporte según condición de churn.

Por último el Boxplot del número de casos de soporte según condición de churn compara los casos de soporte entre clientes sin churn y clientes con churn. En ambos grupos, la mayoría de clientes tiene pocos casos de soporte. Sin embargo, se observan valores extremos, especialmente en el grupo sin churn, donde algunos clientes registran muchos más casos de soporte. En promedio, los clientes sin churn tienen cerca de 0,72 casos de soporte, mientras que los clientes con churn tienen aproximadamente 0,37 casos.

En este gráfico no se observa que los clientes con churn tengan necesariamente más casos de soporte. Por eso, el soporte no parece ser la señal más directa de abandono en este análisis exploratorio. Sin embargo, los valores extremos muestran que algunos clientes sí han requerido mucha atención.

Un mayor número de casos de soporte puede reflejar problemas, dudas o dificultades en la experiencia del cliente. Sin embargo, en esta base también puede interpretarse de otra forma, algunos clientes que piden soporte podrían no abandonar porque reciben ayuda o solución a sus problemas. Por eso, el soporte debe analizarse con cuidado y junto con otras variables como el CHI Score, los logins y los días desde el último ingreso.

Considerando los gráficos anteriores, se identificaron tres patrones principales. Primero, los clientes con churn tienden a tener un CHI Score más bajo, lo que indica una relación más débil con la empresa. Segundo, los clientes con churn presentan menor uso de la plataforma, reflejado en menos logins y más días desde el último ingreso, esto sugiere que la reducción en la actividad es una señal importante de abandono. Tercero, las variables de soporte muestran una relación menos directa: aunque más soporte puede reflejar problemas, en esta base no necesariamente los clientes con churn son los que más soporte reciben. El comportamiento del cliente parece ser clave para entender el churn. Los clientes que abandonan no sólo se diferencian por una variable aislada, sino por un conjunto de señales, menor salud del cliente, menor frecuencia de uso y mayor distancia frente a la plataforma.

4.3 Especificación del modelo de probabilidad binaria

En este análisis, la variable dependiente es Churn, la cual es de naturaleza binaria. Esto implica que solo puede tomar dos valores: 1 si el cliente abandona el servicio y 0 en caso contrario. En consecuencia, el objetivo del modelo no es predecir una variable continua, sino estimar la probabilidad de que ocurra un evento específico, en este caso, el abandono del cliente.

La especificación general del modelo se expresa de la siguiente forma:

$$P(\text{Churn}_i = 1 \mid X_i) = F(\beta_0 + \beta_1 \text{Customer_Age}_i + \beta_2 \text{CHI_Score}_i + \beta_3 \text{CHI_Change}_i + \beta_4 \text{Support_Cases}_i + \beta_5 \text{Support_Cases_Change}_i + \beta_6 \text{Support_Priority}_i + \beta_7 \text{Support_Priority_Change}_i + \beta_8 \text{Logins}_i + \beta_9 \text{Blog_Articles}_i + \beta_{10} \text{Views}_i + \beta_{11} \text{Dayss_Since_Last_Login}_i)$$

Donde $P(\text{Churni}=1|X_i)$ representa la probabilidad de que el cliente i abandone el servicio, condicionada a un conjunto de variables explicativas relacionadas con su comportamiento, nivel de actividad y experiencia con la plataforma. La función F corresponde a una función de distribución acumulada, cuya forma depende del modelo estimado.

El primer modelo considerado es el Modelo de Probabilidad Lineal (MPL), el cual asume una relación lineal entre las variables explicativas y la probabilidad de churn. Su principal ventaja radica en la simplicidad de interpretación, ya que los coeficientes representan cambios marginales directos en la probabilidad. Sin embargo, este modelo presenta una limitación importante dado que, no restringe las predicciones al intervalo $[0,1]$, lo que puede generar probabilidades no válidas. Por esta razón, su uso se justifica principalmente como punto de referencia.

El segundo modelo es el modelo Logit, el cual resulta más apropiado para variables dependientes binarias. Este modelo utiliza una función logística que garantiza que las probabilidades estimadas se encuentren dentro del rango válido. Además, permite capturar relaciones no lineales entre las variables explicativas y la probabilidad de churn. Desde una perspectiva analítica, el modelo Logit es especialmente útil porque facilita la interpretación en términos de cambios en la probabilidad y en razones de odds, lo que lo hace relevante para la toma de decisiones empresariales.

El tercer modelo es el modelo Probit, que también es adecuado para variables binarias, ya que utiliza la función de distribución normal acumulada para estimar probabilidades. Aunque su interpretación es menos directa que en el modelo Logit, ambos modelos suelen generar resultados similares en términos de signos y significancia. La diferencia principal radica en los supuestos sobre la distribución del error, lo que puede influir ligeramente en la forma de la relación estimada.

La estimación de los tres modelos responde a la necesidad de comparar enfoques y validar la consistencia de los resultados. Mientras el MPL ofrece una aproximación inicial sencilla, los modelos Logit y Probit permiten una representación más adecuada del fenómeno de interés, al respetar la naturaleza probabilística del churn.

Finalmente, la especificación del modelo se alinea con el objetivo central del análisis: identificar los factores que influyen en la probabilidad de abandono y generar estimaciones que permitan anticipar el comportamiento de los clientes. A partir de las variables seleccionadas, el modelo transforma información sobre uso, engagement y soporte en una probabilidad estimada de churn, lo que facilita la segmentación de clientes en riesgo y el diseño de estrategias de retención más efectivas.

4.4 Estimación del modelo

Se estimaron tres modelos de probabilidad para analizar la deserción de clientes en QWE Inc., siendo estos el Modelo de Probabilidad Lineal (MPL), el modelo Logit y el modelo Probit.

Todos los modelos incluyen el mismo conjunto de variables explicativas, lo que permite comparar sus resultados de manera consistente y evaluar la robustez de los hallazgos.

Variable	Coefficiente	Error estándar	statistic	Valor p
(Intercept)	0.0636	0.0053	12.0926	0.0000
Customer_Age	0.0008	0.0003	3.0907	0.0020
CHI_Score	-0.0003	0.0001	-4.7035	0.0000
CHI_Change	-0.0004	0.0001	-3.4708	0.0005
Support_Cases	-0.0013	0.0026	-0.4837	0.6286
Support_Cases_Change	0.0029	0.0021	1.3685	0.1712
Support_Priority	-0.0017	0.0038	-0.4628	0.6435
Support_Priority_Change	-0.0002	0.0029	-0.0774	0.9383
Logins	0.0000	0.0001	0.4634	0.6431
Blog_Articles	0.0001	0.0006	0.1241	0.9012
Views	0.0000	0.0000	-0.8833	0.3771
Days_Since_Last_Login	0.0006	0.0002	4.1678	0.0000

Tabla 2. Resultados del Modelo de Probabilidad Lineal (MPL).

A partir de los resultados del MPL, se observa que variables como CHI Score (coeficiente = -0.0003, p-value < 0.01), CHI Change (coeficiente = -0.0004, p-value < 0.01), Customer Age (coeficiente = 0.0008, p-value = 0.0020) y Days Since Last Login (coeficiente = 0.0006, p-value < 0.01) resultan estadísticamente significativas a niveles del 1% y 5%. En estos casos, se rechaza la hipótesis nula de que el coeficiente es igual a cero a favor de la hipótesis alternativa, lo que indica que existe evidencia estadística suficiente para afirmar que dichas variables influyen en la probabilidad de deserción. En términos de signo, el CHI Score y su variación presentan efectos negativos, sugiriendo que mayores niveles de satisfacción y mejoras recientes reducen la probabilidad de churn. Por el contrario, los Days Since Last Login presentan un efecto positivo, lo que indica que una menor actividad del cliente se asocia con un mayor riesgo de abandono. Por otro lado, variables como Support Cases, Support Priority, Logins y Blog Articles no resultan significativas (p-value > 0.10), por lo que no se puede rechazar la hipótesis nula en estos casos.

Variable	Coefficiente	Error estándar	statistic	Valor p
(Intercept)	-2.7627	0.1069	-25.8412	0.0000
Customer_Age	0.0127	0.0054	2.3659	0.0180
CHI_Score	-0.0047	0.0012	-3.8076	0.0001
CHI_Change	-0.0103	0.0025	-4.1526	0.0000
Support_Cases	-0.1524	0.1049	-1.4523	0.1464
Support_Cases_Change	0.1703	0.0905	1.8814	0.0599
Support_Priority	0.0159	0.1022	0.1559	0.8761
Support_Priority_Change	-0.0519	0.0785	-0.6615	0.5083
Logins	0.0003	0.0021	0.1383	0.8900
Blog_Articles	0.0003	0.0196	0.0148	0.9882
Views	-0.0001	0.0000	-2.6966	0.0070
Days_Since_Last_Login	0.0172	0.0043	4.0203	0.0001

Tabla 3. Resultados del Modelo Logit.

Ahora bien, en el modelo logit se mantiene la significancia estadística de varias variables clave. En particular, CHI Score (coeficiente = -0.0047, p-value < 0.01), CHI Change (coeficiente = -0.0103, p-value < 0.01) y Days Since Last Login (coeficiente = 0.0172, p-value < 0.01) son significativas al 1%, lo que implica que se rechaza la hipótesis nula con un alto nivel de confianza. Asimismo, Customer Age (coeficiente = 0.0127, p-value = 0.0180) resulta significativa al 5%, indicando que también tiene un efecto estadísticamente verificable sobre la deserción. Adicionalmente, la variable Views (coeficiente = -0.0001, p-value = 0.0070) es significativa al 1%, lo que sugiere que un mayor nivel de interacción con el contenido reduce la probabilidad de churn. Por otro lado, variables como Support Cases y Support Priority continúan sin ser significativas, mientras que Support Cases Change presenta una significancia marginal (p-value $\approx$ 0.0600), lo que implica que solo sería significativa a un nivel del 10%, proporcionando evidencia débil sobre su efecto.

Variable	Coefficiente	Error estándar	statistic	Valor p
(Intercept)	-1.5572	0.0500	-31.1734	0.0000
Customer_Age	0.0071	0.0026	2.7643	0.0057
CHI_Score	-0.0022	0.0006	-4.0053	0.0001
CHI_Change	-0.0046	0.0012	-3.9824	0.0001

Support_Cases	-0.0576	0.0424	-1.3604	0.1737
Support_Cases_Change	0.0670	0.0365	1.8362	0.0663
Support_Priority	-0.0029	0.0448	-0.0647	0.9484
Support_Priority_Change	-0.0155	0.0347	-0.4467	0.6551
Logins	0.0002	0.0009	0.2382	0.8117
Blog_Articles	-0.0001	0.0085	-0.0167	0.9867
Views	-0.0001	0.0000	-2.3624	0.0182
Days_Since_Last_Login	0.0071	0.0019	3.6427	0.0003

Tabla 4. Resultados del Modelo Probit.

Los resultados del modelo probit son consistentes con los del modelo logit, en donde variables como CHI Score (coeficiente = -0.0022, p-value < 0.01), CHI Change (coeficiente = -0.0046, p-value < 0.01) y Days Since Last Login (coeficiente = 0.0071, p-value < 0.01) son significativas al 1%, lo que permite rechazar la hipótesis nula y afirmar que tienen un efecto estadísticamente significativo sobre la probabilidad de deserción. De igual forma, Customer Age (coeficiente = 0.0071, p-value = 0.0057) es significativa al 1%, mientras que Views (coeficiente = -0.0001, p-value = 0.0182) resulta significativa al 5%. En línea con los modelos anteriores, variables como Support Cases, Support Priority, Logins y Blog Articles no presentan evidencia estadística suficiente para afirmar que influyen en la deserción, dado que sus p-values superan los niveles convencionales de significancia.

De manera conjunta, los tres modelos muestran resultados altamente consistentes tanto en términos de significancia estadística como en el signo de los coeficientes. En particular, variables como CHI Score, CHI Change, Days Since Last Login y Customer Age son significativas en los tres modelos, lo que refuerza la robustez de los hallazgos y permite afirmar con mayor confianza su relación con la deserción. En todos los casos, los efectos negativos asociados a la satisfacción del cliente y los efectos positivos relacionados con la inactividad reflejan patrones coherentes con la lógica del negocio. Asimismo, la variable Views adquiere relevancia en los modelos no lineales, lo que sugiere que ciertos efectos pueden capturarse con mayor precisión en este tipo de especificaciones. En contraste, la falta de significancia de las variables de soporte indica que, dentro de este contexto, no constituyen determinantes clave del churn. De modo que, estos resultados evidencian relaciones estables entre las variables explicativas y la probabilidad de deserción.

4.5 Selección del modelo final

Para seleccionar el modelo más adecuado para analizar la deserción de clientes, se consideran tanto criterios de ajuste estadístico como su utilidad práctica para la empresa. Para ello, se comparan los tres modelos estimados previamente, el Modelo de Probabilidad Lineal (MPL), el modelo Logit y el modelo Probit.

Modelo	R ²	AIC
MPL	0.0153	-1293.0840
Logit	0.0442	2464.3320
Probit	0.0432	2466.7360

Tabla 5. Comparación de modelos (R² y AIC).

A partir de los resultados, se observa que el modelo MPL presenta un R² de 0.0153, lo cual indica un bajo nivel de ajuste, explicando apenas una pequeña proporción de la variabilidad de la variable dependiente. Esto es consistente con las limitaciones conocidas de este modelo cuando se trabaja con variables binarias, ya que puede generar predicciones fuera del rango [0,1] y no captura adecuadamente la naturaleza no lineal de la probabilidad de ocurrencia del evento. En contraste, los modelos logit y probit presentan un mejor desempeño en términos de ajuste, con R² de 0.0442 y 0.0432 respectivamente, lo que evidencia una mayor capacidad para explicar la probabilidad de deserción.

Al comparar los modelos logit y probit, se observa que ambos presentan resultados muy similares. No obstante, el modelo logit muestra un desempeño ligeramente superior, al registrar el menor valor de AIC (2464.332) en comparación con el modelo probit (2466.736). Dado que el criterio AIC penaliza la complejidad del modelo y premia un mejor ajuste, un valor menor indica una mejor especificación relativa. Por lo tanto, esta evidencia sugiere que el modelo logit ofrece un balance más adecuado.

Adicionalmente, desde el punto de vista interpretativo, el modelo logit presenta ventajas relevantes, ya que permite analizar los efectos de las variables explicativas en términos de probabilidades, lo cual resulta particularmente útil en contextos empresariales. En el caso de QWE Inc., esto facilita identificar qué factores incrementan o reducen la probabilidad de que un cliente abandone el servicio, permitiendo priorizar acciones de retención de manera más efectiva. En conjunto, considerando su mejor desempeño en términos de R², su menor valor de AIC y su mayor facilidad de interpretación, se selecciona el modelo logit como el modelo final para el análisis de la deserción de clientes. Este modelo no solo se ajusta mejor a los datos, sino que también proporciona una herramienta más útil para la toma de decisiones dentro de la empresa.

4.6 Interpretación de coeficientes relevantes

El modelo logit estimado ofrece una base para analizar cómo distintos factores asociados a la experiencia y comportamiento del cliente inciden en su decisión de permanecer o abandonar el servicio en QWE Inc. En particular, se analizan variables asociadas a la satisfacción del cliente y al nivel de actividad en la plataforma, dado que presentan significancia estadística y coherencia con el negocio.

Variable	Coeficiente	Error estándar	statistic	Valor p	Odds_Ratio
(Intercept)	-2.7627	0.1069	-25.8412	0.0000	0.0631
Customer_Age	0.0127	0.0054	2.3659	0.0180	1.0128
CHI_Score	-0.0047	0.0012	-3.8076	0.0001	0.9954
CHI_Change	-0.0103	0.0025	-4.1526	0.0000	0.9898
Support_Cases	-0.1524	0.1049	-1.4523	0.1464	0.8587
Support_Cases_Change	0.1703	0.0905	1.8814	0.0599	1.1856
Support_Priority	0.0159	0.1022	0.1559	0.8761	1.0161
Support_Priority_Change	-0.0519	0.0785	-0.6615	0.5083	0.9494
Logins	0.0003	0.0021	0.1383	0.8900	1.0003
Blog_Articles	0.0003	0.0196	0.0148	0.9882	1.0003
Views	-0.0001	0.0000	-2.6966	0.0070	0.9999
Days_Since_Last_Login	0.0172	0.0043	4.0203	0.0001	1.0174

Tabla 6. Resultados del modelo logit final.

En primer lugar, la variable CHI Score presenta un coeficiente negativo (-0.0047) y un odds ratio de 0.9954. Dado que su p-value es menor al 1%, se rechaza la hipótesis nula y se concluye que existe evidencia estadística de su efecto sobre la deserción. En términos empresariales, esto implica que a medida que aumenta el nivel de satisfacción del cliente, disminuye la probabilidad de abandono. Específicamente, un incremento en el CHI Score reduce las probabilidades de churn en aproximadamente un 0.46% ($1 - 0.9954$), lo que sugiere que mejoras en la experiencia del cliente, como calidad del servicio o percepción de valor pueden tener un impacto directo en la retención.

Por otro lado, la variable Days Since Last Login presenta un coeficiente positivo (0.0172) y un odds ratio de 1.0174, siendo significativa al 1%. Esto indica que se rechaza la hipótesis nula y que existe evidencia de que el tiempo de inactividad influye en la deserción. En términos prácticos, por cada incremento en el número de días sin iniciar sesión, las probabilidades de churn aumentan en aproximadamente un 1.74%. Este resultado es especialmente relevante para la empresa, ya que evidencia que la falta de interacción reciente es una señal temprana de riesgo, lo que permitiría implementar estrategias de reactivación, como recordatorios o incentivos, antes de que el cliente abandone definitivamente.

Adicionalmente, la variable CHI Change (coeficiente = -0.0103; odds ratio = 0.9898), significativa al 1%, refuerza la importancia de la dinámica de la satisfacción. En este caso, no solo importa el nivel actual de satisfacción, sino también su evolución por lo que, mejoras

recientes reducen las probabilidades de churn en aproximadamente un 1.02%. Esto sugiere que intervenciones oportunas que mejoren la percepción del cliente pueden ser efectivas incluso en etapas cercanas a la deserción.

Estos resultados muestran que la deserción de clientes en QWE Inc. está fuertemente asociada tanto a factores de satisfacción como de comportamiento. Clientes más satisfechos y con mejoras recientes en su experiencia tienden a permanecer en la plataforma, mientras que aquellos que reducen su nivel de actividad presentan un mayor riesgo de abandono. Esto proporciona una guía clara para la empresa, en donde se debe priorizar estrategias de mejora continua en la experiencia del cliente y monitorear activamente los patrones de uso para anticipar posibles casos de churn

4.7 Evaluación del desempeño del modelo

Una vez estimado el modelo de probabilidad binaria y seleccionada la especificación final (modelo logit), resulta fundamental evaluar su capacidad predictiva y su desempeño tanto en términos estadísticos como prácticos. Esta evaluación permite determinar en qué medida el modelo logra capturar la relación entre las variables explicativas y la probabilidad de deserción, así como su utilidad para apoyar la toma de decisiones en la empresa.

De modo que se analizan diferentes métricas y herramientas complementarias, incluyendo el coeficiente de determinación, el comportamiento de los errores y la capacidad de clasificación del modelo mediante la comparación entre valores reales y predichos. Asimismo, se incorporan medidas adicionales que permiten evaluar de forma más integral el desempeño del modelo y comprender con mayor precisión sus principales fortalezas y limitaciones.

4.7.1 Análisis de las probabilidades estimadas

Una vez seleccionado el modelo logit como la mejor especificación, resulta pertinente analizar el comportamiento de las probabilidades estimadas en función del resultado real, con el propósito de evaluar su capacidad para diferenciar entre clientes que presentan churn y aquellos que no.

La distribución de las probabilidades estimadas muestra que los clientes que presentan churn tienden a registrar valores ligeramente superiores en comparación con aquellos que no presentan deserción. Sin embargo, también se observa una superposición entre ambos grupos, lo que indica que el modelo no logra una separación completamente clara entre ellos.

Adicionalmente, la mayor parte de las probabilidades estimadas se concentra en niveles relativamente bajos, lo que sugiere que el modelo tiende a asignar valores moderados incluso a clientes que efectivamente presentan churn. Este comportamiento refleja la dificultad inherente de predecir la deserción y es consistente con los niveles de ajuste observados en la sección anterior.




Ilustración 6. Boxplot de la probabilidad estimada de churn según el resultado real.

Estos resultados evidencian que el modelo captura parcialmente las diferencias entre los grupos, aunque con limitaciones en su capacidad de discriminación, lo que justifica la necesidad de complementar el análisis con otras herramientas de evaluación en las siguientes secciones.

4.7.2 Gráfico de errores

El análisis de los errores permite examinar la diferencia entre los valores observados de la variable de churn y las probabilidades estimadas por el modelo, proporcionando información clave sobre la precisión y el comportamiento de las predicciones. En este caso, el error se define como la diferencia entre el valor real y la probabilidad estimada, lo que permite identificar tanto subestimaciones como sobreestimaciones en la estimación del riesgo.




Ilustración 7. Gráfico de errores del modelo final.

A partir del gráfico, se observa que los errores se distribuyen en dos zonas claramente diferenciadas. Los errores positivos corresponden a aquellos casos en los que el cliente presenta churn, pero el modelo asigna probabilidades relativamente bajas, lo que refleja una subestimación del riesgo. Por su parte, los errores negativos se presentan cuando el cliente no experimenta churn y el modelo asigna probabilidades positivas, evidenciando una sobreestimación del riesgo.

Se aprecia que la mayoría de las probabilidades estimadas se concentran en valores bajos, en general por debajo de 0.20. Esta concentración explica la presencia de errores positivos relativamente altos en algunos casos, ya que el modelo no logra asignar probabilidades suficientemente elevadas a clientes que efectivamente abandonan el servicio. En otras palabras, el modelo presenta dificultades para identificar con alta certeza a los clientes con mayor riesgo de churn.

Adicionalmente, la disposición de los puntos en el gráfico sigue una estructura lineal característica de este tipo de modelos, lo que indica coherencia en la forma en que se generan los errores. No se observan patrones irregulares ni dispersión aleatoria significativa, lo que sugiere estabilidad en el comportamiento del modelo.




Ilustración 8. Error absoluto según probabilidad estimada.

El análisis del error absoluto muestra que la magnitud de los errores tiende a incrementarse a medida que la probabilidad estimada se aleja del valor real observado. Esto se evidencia particularmente en aquellos casos en los que el modelo asigna probabilidades bajas a clientes que presentan churn o probabilidades relativamente altas a clientes que no lo presentan, generando desviaciones más pronunciadas.

En conjunto, los resultados evidencian que el modelo mantiene consistencia en la forma en que comete errores, aunque presenta una limitación relevante asociada a la asignación de

probabilidades moderadas, lo que reduce su capacidad para identificar con mayor precisión a los clientes con riesgo elevado de deserción.

4.7.3 Matriz de confusión

La matriz de confusión permite evaluar la capacidad del modelo para clasificar correctamente a los clientes según la ocurrencia de churn, comparando los valores reales con las predicciones obtenidas a partir de las probabilidades estimadas. En este caso, se utiliza un umbral de clasificación de 0.10 con el objetivo de mejorar la identificación de clientes con riesgo de deserción, dado que las probabilidades estimadas se concentran en niveles relativamente bajos.

	Predicho 0	Predicho 1
Real 0	5592	432
Real 1	237	86

Tabla 7. Matriz de confusión del modelo logit con umbral de clasificación de 0.10.

A partir de los resultados, se observa que el modelo clasifica correctamente 5592 clientes sin churn (verdaderos negativos) y 86 clientes con churn (verdaderos positivos). Adicionalmente, se identifican 432 casos en los que el modelo predice churn en clientes que no presentan deserción (falsos positivos), así como 237 casos en los que no logra identificar clientes que efectivamente presentan churn (falsos negativos).

Estos resultados evidencian que el modelo logra capturar una proporción relevante de los clientes que presentan churn, lo cual representa una mejora en la capacidad de detección frente a esquemas de clasificación más restrictivos. Al mismo tiempo, se observa una mayor identificación de clientes potencialmente en riesgo, lo que amplía el alcance de las estrategias de intervención.

Desde una perspectiva aplicada, este comportamiento permite fortalecer la capacidad de anticipación del modelo, facilitando la identificación temprana de clientes con posible riesgo de deserción. De esta manera, la empresa puede orientar acciones preventivas sobre un conjunto más amplio de clientes, contribuyendo a mejorar la gestión del churn y la toma de decisiones en procesos de retención.

4.7.4 Métricas de clasificación

Las métricas de desempeño permiten resumir la capacidad del modelo para clasificar correctamente a los clientes, complementando la información obtenida a partir de la matriz de confusión. Estas medidas facilitan la evaluación del equilibrio entre la correcta identificación de clientes con churn y la clasificación adecuada de aquellos que no presentan deserción.

Métrica	Valor
Accuracy	0.8946
Precision	0.1660
Recall	0.2663
Specificity	0.9283

Tabla 8. Métricas de desempeño del modelo logit con umbral de clasificación de 0.10.

A partir de los resultados, se observa que el modelo alcanza un nivel de accuracy de 0.8946, lo que indica que aproximadamente el 89.46% de las observaciones son clasificadas correctamente. Este valor refleja un buen desempeño general en términos de clasificación global.

Sin embargo, al analizar métricas más específicas, se identifican diferencias relevantes en el comportamiento del modelo. La precisión (precision) presenta un valor de 0.1660, lo que indica que una proporción relativamente baja de los clientes clasificados como churn efectivamente corresponden a casos reales de deserción. Por su parte, el recall alcanza un valor de 0.2663, lo que evidencia que el modelo logra identificar cerca del 26.63% de los clientes que presentan churn.

En contraste, la especificidad presenta un valor elevado de 0.9283, lo que indica que el modelo clasifica correctamente la gran mayoría de los clientes que no presentan churn. Este resultado es consistente con la distribución de la variable dependiente, en la cual predominan los clientes sin deserción.

En conjunto, estas métricas muestran que el modelo presenta un buen desempeño en la identificación de clientes sin churn, mientras que su capacidad para detectar clientes con deserción es más limitada. No obstante, el uso de un umbral de clasificación más bajo permite mejorar la detección de estos casos en comparación con esquemas más restrictivos, ampliando el alcance de las estrategias de retención.

4.7.5 Curva ROC y capacidad de discriminación del modelo

La curva ROC (Receiver Operating Characteristic) permite evaluar la capacidad del modelo para discriminar entre clientes que presentan churn y aquellos que no, independientemente del umbral de clasificación utilizado. A diferencia de las métricas basadas en un punto de corte específico, esta herramienta considera todos los posibles valores de clasificación, proporcionando una visión más completa del desempeño del modelo.




Ilustración 9. Curva ROC del modelo logit.

La curva se ubica por encima de la línea diagonal de referencia, la cual representa el comportamiento de un modelo sin capacidad predictiva. Esta posición indica que el modelo logra distinguir entre clientes con y sin churn en un nivel superior al azar.

Su forma evidencia un incremento progresivo de la sensibilidad a medida que disminuye la especificidad, reflejando el trade-off natural entre la identificación de clientes con churn y la correcta clasificación de aquellos que no presentan deserción. Este comportamiento es consistente con lo observado en las métricas de desempeño, donde el modelo muestra mayor efectividad en la clasificación de clientes sin churn.

El área bajo la curva (AUC) resume esta capacidad en un único valor, interpretado como la probabilidad de que el modelo asigne una mayor puntuación a un cliente con churn que a uno sin churn. Aunque no se reporta explícitamente el valor numérico, la forma de la curva sugiere un desempeño moderado en términos de discriminación. La evidencia presentada confirma que el modelo cuenta con una capacidad adecuada para diferenciar entre ambos grupos de clientes, lo que respalda su uso como herramienta de apoyo en la identificación del riesgo de churn.

4.8 Identificación de clientes con mayor riesgo de churn

El análisis del churn no solo permite identificar los factores asociados al abandono, sino también priorizar clientes según su nivel de riesgo. En este contexto, se construye un ranking que ordena a los clientes de acuerdo con la probabilidad estimada de abandonar el servicio, lo cual facilita la toma de decisiones enfocadas en retención.

ID_Cliente	Churn	Probabilidad_Churn	Prediccion_Churn	Error_Absoluto
2287	0	0.3963	1	0.3963
357	1	0.3501	1	0.6499
109	0	0.3004	1	0.3004
1971	0	0.2471	1	0.2471
2076	0	0.2162	1	0.2162
2025	0	0.2153	1	0.2153
1	0	0.2015	1	0.2015
76	0	0.1936	1	0.1936
929	0	0.1933	1	0.1933
1363	1	0.1905	1	0.8095
299	1	0.1890	1	0.8110
1287	0	0.1888	1	0.1888
2244	0	0.1873	1	0.1873
1929	0	0.1838	1	0.1838
14	0	0.1818	1	0.1818
1672	1	0.1803	1	0.8197
18	0	0.1781	1	0.1781
3	0	0.1781	1	0.1781
21	0	0.1762	1	0.1762
1459	0	0.1744	1	0.1744
128	0	0.1707	1	0.1707
1286	0	0.1696	1	0.1696
1021	1	0.1688	1	0.8312
1520	0	0.1684	1	0.1684
2546	0	0.1683	1	0.1683
1236	0	0.1676	1	0.1676
2599	0	0.1670	1	0.1670

2922	1	0.1670	1	0.8330
51	0	0.1666	1	0.1666
2951	1	0.1664	1	0.8336
1862	0	0.1650	1	0.1650
183	0	0.1647	1	0.1647
335	1	0.1644	1	0.8356
2080	0	0.1639	1	0.1639
2240	0	0.1637	1	0.1637
2680	0	0.1623	1	0.1623
59	0	0.1620	1	0.1620
3340	1	0.1616	1	0.8384
1616	0	0.1616	1	0.1616
1143	0	0.1612	1	0.1612
55	0	0.1612	1	0.1612
2481	0	0.1605	1	0.1605
121	0	0.1602	1	0.1602
137	0	0.1585	1	0.1585
1574	0	0.1577	1	0.1577
2838	0	0.1577	1	0.1577
154	0	0.1569	1	0.1569
3671	0	0.1557	1	0.1557
146	0	0.1556	1	0.1556
119	0	0.1552	1	0.1552
171	0	0.1552	1	0.1552
190	0	0.1552	1	0.1552
5	0	0.1551	1	0.1551
3604	1	0.1549	1	0.8451
42	0	0.1549	1	0.1549

4245	0	0.1544	1	0.1544
1204	0	0.1543	1	0.1543
2289	0	0.1539	1	0.1539
2	0	0.1538	1	0.1538
101	0	0.1535	1	0.1535
2924	0	0.1523	1	0.1523
95	0	0.1505	1	0.1505
61	0	0.1500	1	0.1500
68	0	0.1498	1	0.1498
798	0	0.1490	1	0.1490
156	1	0.1487	1	0.8513
1438	0	0.1486	1	0.1486
1141	0	0.1481	1	0.1481
1392	0	0.1481	1	0.1481
123	0	0.1481	1	0.1481
2739	0	0.1477	1	0.1477
89	0	0.1475	1	0.1475
868	0	0.1468	1	0.1468
203	0	0.1468	1	0.1468
2242	0	0.1466	1	0.1466
106	0	0.1465	1	0.1465
1693	0	0.1462	1	0.1462
1151	0	0.1460	1	0.1460
1019	0	0.1459	1	0.1459
3042	0	0.1457	1	0.1457
1393	0	0.1452	1	0.1452
3124	0	0.1446	1	0.1446
2255	0	0.1439	1	0.1439

1395	0	0.1439	1	0.1439
1478	0	0.1439	1	0.1439
2235	0	0.1439	1	0.1439
69	0	0.1431	1	0.1431
1488	1	0.1426	1	0.8574
2830	0	0.1425	1	0.1425
10	0	0.1421	1	0.1421
2296	1	0.1408	1	0.8592
246	0	0.1403	1	0.1403
3076	0	0.1398	1	0.1398
1155	0	0.1396	1	0.1396
142	0	0.1395	1	0.1395
62	0	0.1388	1	0.1388
2656	0	0.1384	1	0.1384
1908	0	0.1378	1	0.1378
2913	0	0.1371	1	0.1371
2286	0	0.1367	1	0.1367

Tabla 9. Ranking de clientes con mayor riesgo de churn.

El ranking se construye en varios pasos a partir del modelo Logit. En primer lugar, el modelo estima la probabilidad de churn para cada cliente utilizando sus características observadas. En segundo lugar, se define un umbral de clasificación de 0.10, de modo que aquellos clientes con una probabilidad igual o superior a este valor son considerados en riesgo (Prediccion_Churn = 1). Posteriormente, se calcula el error absoluto como la diferencia entre el valor real de churn y la probabilidad estimada, lo que permite evaluar la precisión individual de cada predicción. Finalmente, los clientes se ordenan de forma descendente según su probabilidad estimada de churn.

Este ranking representa una herramienta de priorización, donde los clientes ubicados en las primeras posiciones son aquellos que el modelo considera más propensos a abandonar. La tabla incluye variables clave como el identificador del cliente, el valor real de churn, la probabilidad estimada, la clasificación del modelo y el error absoluto, lo que permite analizar tanto el riesgo como el desempeño predictivo.

Al interpretar los resultados, se observa que los clientes con mayor probabilidad estimada tienden a presentar patrones asociados con menor vinculación a la plataforma. Por ejemplo, pueden reflejar una disminución en indicadores como el CHI Score, menor frecuencia de uso (logins o views) o un aumento en los días desde el último ingreso. Estas señales son consistentes con los hallazgos del análisis exploratorio y del modelo econométrico, lo que refuerza la validez del ranking.

Por ejemplo, algunos clientes con probabilidades cercanas o superiores al 30% aparecen en las primeras posiciones. En ciertos casos, el modelo logra identificar correctamente clientes que efectivamente abandonaron, lo que evidencia su capacidad predictiva. Sin embargo, también se presentan clientes con alta probabilidad que no abandonaron, lo cual es esperable en modelos probabilísticos. Esto no implica un error, sino que estos clientes comparten características similares con aquellos que sí hicieron churn, por lo que pueden interpretarse como casos de riesgo potencial o alerta temprana.

Desde una perspectiva empresarial, este ranking es altamente útil porque permite enfocar los recursos de manera estratégica. En lugar de aplicar acciones generales, la empresa puede priorizar intervenciones sobre los clientes con mayor riesgo estimado. Esto incluye estrategias como contacto proactivo, ofertas de retención, seguimiento personalizado o mejoras en la experiencia del cliente. En este sentido, el ranking no solo identifica riesgo, sino que se convierte en una herramienta operativa para reducir el churn y mejorar la relación con los clientes.

4.9 Principales drivers del churn

Con el fin de identificar los factores que explican el abandono de clientes, se analizan los principales drivers del churn a partir de los resultados del modelo Logit, considerando tanto la dirección del efecto como su relevancia estadística.

Variable	Coficiente	Odds_Ratio	Valor p
Support_Cases_Change	0.170263	1.185617	0.059919
Support_Cases	-0.152370	0.858670	0.146430
Support_Priority_Change	-0.051937	0.949389	0.508299
Days_Since_Last_Login	0.017242	1.017392	0.000058
Support_Priority	0.015929	1.016057	0.876111
Customer_Age	0.012706	1.012787	0.017988
CHI_Change	-0.010275	0.989778	0.000033
CHI_Score	-0.004657	0.995354	0.000140
Blog_Articles	0.000290	1.000291	0.988174

Logins	0.000289	1.000289	0.890017
Views	-0.000110	0.999890	0.007005

Tabla 10. Principales drivers del churn.

La tabla resume los coeficientes estimados, sus respectivos odds ratios y los valores p asociados. El coeficiente indica la dirección del efecto sobre la probabilidad de churn, mientras que el odds ratio permite interpretar el cambio en la razón de probabilidades ante un incremento unitario en la variable. Por su parte, el valor p permite evaluar la evidencia estadística, contrastando la hipótesis nula de que el coeficiente es igual a cero frente a la alternativa de que es distinto de cero.

En términos de significancia estadística, se observa que variables como Days_Since_Last_Login ($p = 0.0001$), CHI_Change ($p = 0.0000$), CHI_Score ($p = 0.0001$) y Views ($p = 0.0070$) son significativas al 1%, lo que implica que se rechaza la hipótesis nula y existe evidencia estadística robusta de su relación con el churn. Asimismo, Customer_Age ($p = 0.0180$) resulta significativa al 5%, mientras que Support_Cases_Change ($p = 0.0599$) presenta significancia marginal al 10%.

Una de las variables con mayor relevancia es Days_Since_Last_Login, cuyo coeficiente positivo (0.0172) y odds ratio de 1.0174 indican que, a medida que aumentan los días sin interacción, se incrementa la probabilidad de churn. Este resultado es consistente con la lógica del negocio, ya que refleja una pérdida progresiva de engagement del cliente.

Por otro lado, CHI_Score y CHI_Change presentan coeficientes negativos y significativos, lo que indica que un mayor nivel o mejora en el estado del cliente reduce la probabilidad de abandono. Sus odds ratios menores a 1 confirman que estas variables actúan como factores protectores frente al churn.

La variable Views, aunque presenta un coeficiente pequeño (-0.0001), resulta estadísticamente significativa. Esto se explica por su escala, y sugiere que una mayor interacción con la plataforma está asociada con una menor probabilidad de abandono.

En contraste, variables como Support_Cases, Support_Priority, Logins y Blog_Articles no resultan estadísticamente significativas ($p > 0.10$), por lo que no se puede rechazar la hipótesis nula. Esto implica que, aunque algunas presentan coeficientes relativamente grandes, no existe suficiente evidencia para afirmar que tengan un efecto sistemático sobre el churn dentro del modelo.

En conjunto, los principales drivers del churn están asociados con tres dimensiones: nivel de actividad del cliente, estado o salud de la relación (CHI) y señales de desconexión. Estos resultados sugieren que el abandono no responde a un único factor, sino a un deterioro progresivo en la interacción y el valor percibido del servicio.

Desde una perspectiva empresarial, estos hallazgos permiten enfocar estrategias en la reactivación de clientes inactivos, el monitoreo del CHI Score como indicador temprano y la identificación de patrones de uso decreciente. De esta forma, la empresa puede anticiparse al churn y diseñar intervenciones más efectivas.

5. 4D de las IA

5.1 Definir

En el desarrollo del caso de Predicting Customer Churn, el grupo tuvo claridad desde el inicio sobre el objetivo principal del análisis que era identificar los factores que inciden en la desertión de clientes y estimar un modelo que permitiera predecir dicha probabilidad. Antes de recurrir a herramientas de inteligencia artificial, se definió que el enfoque metodológico estaría basado en modelos de probabilidad para variable binaria (MPL, logit y probit), así como en la evaluación de su desempeño y capacidad explicativa.

En cuanto al uso de la inteligencia artificial, el grupo fue consciente de sus capacidades y limitaciones, por lo que se utilizó principalmente como apoyo en tareas operativas y repetitivas, como la estructuración del código en R, la depuración de errores y la generación de formatos iniciales para tablas y visualizaciones. Sin embargo, se reconoció que la IA puede presentar limitaciones en la interpretación económica de los resultados y en la comprensión del contexto específico del negocio, por lo que estas decisiones se mantuvieron bajo el criterio del equipo..

De esta forma, la distribución de tareas combinó las fortalezas de ambas partes, la IA como herramienta de apoyo técnico para optimizar el proceso de programación y organización de resultados, y el grupo como responsable del razonamiento analítico, la validación de los resultados y su interpretación en términos empresariales. Este enfoque permitió no solo mejorar la eficiencia en el desarrollo del trabajo, sino también asegurar que las conclusiones estuvieran fundamentadas en un entendimiento real del problema y no únicamente en la automatización del análisis.

5.2 Diagnosticar

En el desarrollo del caso, el uso de la inteligencia artificial requirió la construcción de prompts claros y progresivamente más precisos. Inicialmente, el grupo partió de instrucciones generales, sin embargo, se evidenció que la calidad de la respuesta dependía directamente del nivel de detalle proporcionado, por lo que fue necesario incorporar contexto sobre los datos, las librerías utilizadas y el formato de salida esperado.

Uno de los primeros prompts utilizados fue: "Tengo un dataset de churn de clientes en R. Ayúdame a hacer un modelo logit y ver qué variables son importantes." Este prompt no funcionó muy bien, ya que la respuesta obtenida fue demasiado general y no se ajustaba completamente a la estructura del trabajo. No consideraba los nombres específicos de las variables, ni las librerías utilizadas, ni el formato requerido para la entrega. Como resultado,

fue necesario refinar el prompt para hacerlo más específico y alineado con el contexto del análisis.

Posteriormente, se utilizó un prompt más completo: "Estoy trabajando en R con un dataset llamado `data_modelo` que incluye la variable dependiente Churn (binaria) y variables como `Customer_Age`, `CHI_Score`, `CHI_Change`, `Support_Cases` y `Days_Since_Last_Login`. Estoy usando librerías como `dplyr`, `ggplot2`, `broom` y `tidyr`. Quiero estimar un modelo logit (glm con `family = binomial`), obtener una tabla de coeficientes con errores estándar y p-values, y exportarla en un formato claro para un informe." Este segundo prompt resultó mucho más efectivo, ya que incluía el contexto del dataset, el objetivo específico (estimar el modelo y presentar resultados) y restricciones claras sobre el formato de salida. Además, permitió obtener un código más estructurado y directamente utilizable, reduciendo el tiempo de depuración.

A lo largo del proceso, el grupo fue ajustando las instrucciones en función de los resultados obtenidos. En donde fue necesario dividir tareas complejas en pasos más pequeños, como solicitar primero la limpieza de datos, luego la estimación del modelo y posteriormente la generación de tablas y gráficos. Asimismo, se identificó que incluir detalles como nombres exactos de variables, librerías utilizadas como `readxl`, `dplyr`, `ggplot2`, `tidyr` y el formato esperado de salida era fundamental para mejorar la precisión de las respuestas. Esto permitió aprovechar de manera más eficiente las capacidades de la IA, asegurando que las soluciones generadas fueran coherentes con los requerimientos del caso.

5.3 Discernimiento

El grupo asumió una postura crítica frente al uso de la inteligencia artificial, entendiendo que, aunque fue útil en la construcción del código, los resultados debían ser validados cuidadosamente. En donde, se evitó asumir que un código que corre sin errores es necesariamente correcto, por lo que cada salida fue contrastada con el conocimiento estadístico y la lógica del problema.

Un ejemplo claro de este proceso se presentó en la etapa inicial de análisis descriptivo, donde algunas salidas generadas requerían revisión para asegurar su coherencia. En particular, se verificó que las magnitudes de las variables y sus rangos fueran consistentes con su interpretación, evitando posibles errores de escalas. Esta validación permitió confirmar que los datos estaban siendo leídos y procesados correctamente antes de avanzar a etapas más complejas del análisis.

De manera similar, en la estimación de los modelos, el grupo revisó que la especificación propuesta en el código correspondiera efectivamente a un modelo adecuado para una variable binaria. Aunque la IA sugería el uso de funciones como `glm`, fue necesario comprobar que la familia binomial y el enlace logit estuvieran correctamente definidos. Además, se contrastaron los resultados obtenidos con las salidas directas de `summary()`, asegurando que los coeficientes, signos y niveles de significancia fueran consistentes y tuvieran sentido en el contexto del comportamiento del cliente.

Otro aspecto relevante fue la validación de los resultados de predicción. En este punto, se revisó que la construcción de la matriz de confusión y las métricas de clasificación reflejaran correctamente la capacidad del modelo. Por ejemplo, se evaluó si los niveles de acierto eran razonables o si podrían estar influenciados por la distribución de la variable dependiente, evitando conclusiones engañosas sobre el desempeño del modelo.

Este proceso evidenció que la IA, aunque útil para agilizar la programación, puede generar resultados que requieren ajustes o verificación adicional. Por lo que, el grupo mantuvo el control sobre la validación de los outputs, asegurando que cada resultado fuera coherente, defendible y alineado con el problema de negocio. Este ejercicio de discernimiento fue clave para garantizar la calidad y credibilidad del análisis final.

5.4 Diligencia

En cuanto a la diligencia, el grupo asumió la responsabilidad de garantizar que cada resultado presentado fuera comprendido, validado y defendible. Aunque la inteligencia artificial fue utilizada como apoyo en la construcción del código en R, todas las decisiones analíticas desde la selección de variables hasta la interpretación de los resultados fueron realizadas y revisadas directamente por el grupo, asegurando un uso ético y consciente de la herramienta.

El resultado del que se tiene mayor nivel de confianza es la identificación de las variables significativas dentro del modelo logit, particularmente aquellas relacionadas con el nivel de actividad del cliente y su interacción reciente con la plataforma. Esto se debe a que los signos, magnitudes y niveles de significancia son consistentes tanto entre modelos como con la lógica del negocio, lo que permite afirmar con solidez que estas variables tienen un efecto relevante sobre la probabilidad de churn. Por el contrario, los resultados que generan mayor cautela están asociados a variables con baja significancia estadística o efectos marginales muy pequeños, ya que, aunque el modelo las incluye, su impacto no es lo suficientemente robusto como para extraer conclusiones fuertes.

En cuanto al rol de la IA, su participación se concentró principalmente en la generación y organización del código, incluyendo la estructuración de modelos, tablas y algunos gráficos. Sin embargo, el grupo se encargó de revisar, ajustar y validar cada uno de estos elementos, evitando depender ciegamente de las salidas generadas. Este enfoque permitió asegurar que el análisis no solo fuera técnicamente correcto, sino también comprensible y justificable.

Finalmente, el grupo considera que podría defender los resultados obtenidos sin depender del script, ya que se comprende la lógica detrás de cada modelo, la interpretación de los coeficientes y las implicaciones para la empresa. En este sentido, la diligencia se reflejó no solo en el uso responsable de la IA, sino también en la apropiación del análisis, garantizando que el trabajo entregado sea coherente, transparente y defendible.

6. Conclusiones y recomendaciones

El análisis realizado permite concluir que el churn en QWE Inc. constituye un problema relevante, aunque se presenta en una proporción relativamente baja dentro de la base de clientes. En la muestra analizada, aproximadamente el 5,09% de los clientes abandonan el servicio, mientras que el 94,91% permanece activo. Esto implica que la base se encuentra desbalanceada, por lo que el principal reto no es predecir correctamente a la mayoría, sino identificar de manera oportuna a ese grupo reducido que presenta riesgo de deserción.

Uno de los hallazgos más importantes es que el comportamiento del cliente desempeña un papel central en la explicación del churn. En particular, los clientes que abandonan tienden a presentar un CHI Score más bajo, menor nivel de uso de la plataforma y un mayor número de días desde su último login. Estos resultados evidencian que el abandono no ocurre de forma repentina, sino que está precedido por señales de desconexión, disminución en la actividad y un deterioro progresivo en la relación con la empresa.

En línea con lo anterior, las variables más relevantes para explicar el churn fueron Days_Since_Last_Login, CHI_Score, CHI_Change, Views y Customer_Age. Específicamente, los días desde el último ingreso presentan un efecto positivo sobre la probabilidad de abandono, lo que indica que a medida que un cliente deja de interactuar con la plataforma, aumenta su riesgo de churn. Por el contrario, un mayor CHI Score, mejoras en el CHI y un mayor número de visualizaciones se asocian con una menor probabilidad de abandono, lo que refuerza la idea de que los clientes más activos y con mejor relación con la empresa tienden a permanecer en el tiempo.

Por otro lado, las variables relacionadas con el soporte deben interpretarse con cautela. Aunque incrementos en los casos de soporte pueden reflejar problemas o fricciones en la experiencia del cliente, los resultados no muestran evidencia consistente de que estas variables sean determinantes directas del churn. Esto sugiere que el soporte, más que un detonante del abandono, puede funcionar como un mecanismo de contención, especialmente cuando los problemas del cliente son atendidos de manera oportuna y efectiva.

En cuanto a los modelos estimados, el modelo Logit fue seleccionado como la mejor alternativa, al presentar un balance adecuado entre ajuste, capacidad predictiva e interpretación económica frente al MPL y el Probit. Además, su estructura es consistente con la naturaleza binaria de la variable dependiente, garantizando probabilidades dentro del rango [0,1]. No obstante, es importante reconocer sus limitaciones, aunque el modelo logra identificar patrones relevantes y algunos clientes en riesgo, no separa de manera perfecta a los clientes con churn de aquellos que no abandonan, lo que se refleja en la superposición de probabilidades estimadas y en la concentración de valores en niveles bajos.

A partir de estos hallazgos, se desprenden varias implicaciones prácticas. En primer lugar, resulta fundamental fortalecer el monitoreo del CHI Score como indicador de salud del cliente. Caídas en este indicador deberían activar mecanismos de intervención temprana, como contacto personalizado, revisión de la experiencia del cliente o acompañamiento por parte del

equipo de customer success. En segundo lugar, la empresa debería promover activamente el uso de la plataforma, dado que una mayor interacción está asociada con menor churn. Estrategias como recordatorios, contenido personalizado, campañas de reactivación y seguimiento a clientes inactivos pueden contribuir a fortalecer el vínculo con el servicio.

Adicionalmente, el ranking de clientes según probabilidad de churn ofrece una herramienta clave para la priorización de esfuerzos. En lugar de aplicar estrategias generalizadas, la empresa puede enfocar sus recursos en aquellos clientes con mayor riesgo estimado, optimizando así el impacto de las acciones de retención. Sin embargo, es importante que el modelo se utilice como un insumo complementario y no como una decisión definitiva. Su uso debe integrarse con información cualitativa relevante, como historial de interacción, tipo de cliente, valor económico y retroalimentación del equipo comercial.

En conclusión, el análisis muestra que QWE Inc. tiene la oportunidad de transitar de un enfoque reactivo a uno preventivo en la gestión del churn. Al anticipar el abandono a partir de señales de comportamiento, la empresa puede intervenir de manera oportuna, mejorar la experiencia del cliente y fortalecer su estrategia de retención. Esto no solo contribuye a reducir la deserción, sino también a optimizar recursos y proteger el valor de largo plazo de la base de clientes.